

Łacina tekstów praktyki w świetle analizy korpusowej

Prolegomena

Krzysztof Nowak
Pracownia Łaciny Średniowiecznej
Instytut Języka Polskiego PAN


1. Projekt eFontes
2. Piśmienność pragmatyczna w korpusie
3. Analiza tekstów praktyki
 - stan badań
 - postulaty
4. Analiza korpusowa
5. Topic Modelling
6. Ortografia i składnia
7. Formulaiczność
8. Zmiana leksykalna
9. Wnioski

eFontes

corpus.scripores.pl

Założenia

- elektroniczny
- ogólny
- historyczny



Reprezentatywność


- język łaciński
- ziemie polskie
- ca. 1000 - ca. 1550

editiones.scriptores.pl



Reprezentatywność

Piśmiennictwo



Korpus


Wymiary

- czas
- miejsce
- typ tekstu

Problemy

- populacja
- próbka
- populacja → próbka


Piśmienność pragmatyczna w korpusie




AKapSądPozn




FormJ




KsgMa31




KsgRachKr




KsgPrzem




KsgSądBrzes



PomnLw1



PomnLw2




StPPP11

Problemy

- jednostka analizy
 - zapiska $\neq$ księga
 - odpis $\neq$ kartularz itd.
- nielinearność tekstów
 - wykreślenia i uzupełnienia
 - wersje, kopie
- metadane
 - czas
 - miejsce
 - nadawca
 - odbiorca

językoznanstwo historyczne jako „sztuka czynienia najlepszego użytku ze złych danych (bad data)” (Labov 1994)



język źródła

- skryba
- autor
- wydawca

metadane

- wątpliwe
- nieostre

Ku analizie tekstów praktyki

wielkoskalowa

empiryczna

- obiektywizacja opisu istniejących konstruktyw badawczych
- wyłonienie nowych przedmiotów badań

wieloczynnikowa


- wszystkie poziomy organizacji języka
- zróżnicowanie i zmiana

interpretowalna



- *distant reading* i *close reading*
- generowanie hipotez
- weryfikacja hipotez



Stan badań

Bibliografie, katalogi, monografie





Leksykografia i syntezy





Studia filologiczne



Studia nad Kanzleisprache



Analiza korpusowa

Konkordancja, kolokacja, dystrybucja



- *Begriffsgeschichte*
- semantyka historyczna
- *lexicométrie*



Analiza kolokaciji: *potestas*

1	omnimodus	6	legatus	11	auctoritas	16	loco
2	plenus	7	mandatum	12	substituo	17	eradico
3	facultas	8	latus	13	regnum	18	liber
4	trado	9	plenitudo	14	instituo	19	secularis
5	concedo	10	habeo	15	attribuo	20	specialis

Dystrybucja w tekstach: *potestas*


Lp.	Tytuł	Liczba wystąpień
1	Kodeks listów z XV w.	69
2	Kodeks dyplomatyczny UJ 2	51
3	Akta grodzkie i ziemskie 3	35
4	Kodeks dyplomatyczny UJ 1	33
5	Acta capituli Gneznensis	33
6	Kodeks dyplomatyczny Polski 1	29
7	Akta grodzkie i ziemskie 4	29
8	Kodeks dyplomatyczny Polski 2	26
9	Akta radzieckie poznański	24
10	Najstarsze księgi i rachunki miasta Krakowa	22
11	Najdawniejsze zapiski sądów sanockich	20
12	Księgi gromadzkie wsi Krościenko	20
13	Najstarsze wielkopolskie księgi grodzkie 1	19
14	Vita sanctissimi Stanislai episcopi Cracoviensis	19
15	Księgi sądowe brzeskie	19
16	Kronika Polska W. Kadłubka	19

Analiza porównawcza

Leksem	Frekwencja
auctoritas	784
mandatum	780
potestas	613
facultas	546


<i>auctoritas</i>	<i>facultas</i>	<i>mandatum</i>	<i>potestas</i>
Kod. dypl. UJ 2	Ks. ławn. krak.	Acta cap. Gnezn.	Kod. listów XV w.
Kod. dypl. UJ 1	Ks. ławn. krak.	Ks. sąd. brzeskie	Kod. dypl. UJ 2
Kod. dypl. Pol. 2	Acta cap. Gnezn.	Kod. listów XV w.	AGZ III
Kod. listów XV w.	Kod. dypl. Pol. 1	Kod. dypl. UJ 2	Kod. dypl. UJ 1
AGZ IV	Kod. listów XV w.	Kod. dypl. Pol. 2	Acta cap. Gnezn.

statystyka leksykalna i lingwistyka tekstu




Jan Długosz: długość tekstu a rok

semantyka dystrybucyjna




topic modelling




Zróżnicowanie. Temat, ortografia, składnia


Topic Modelling. Korpus




Topic Modelling. Piśmienność pragmatyczna



Ortografia. Korpus



Ortografia. Piśmienność pragmatyczna



Ortografia. Analiza skupień

PCA Variance Explained:

Total (2 components): 73.7%

Top Contributing Features:

ti_ci:

Overall importance: 1.041

i_y:

Overall importance: 0.950

z_s:

Overall importance: 0.933

i_j:

Overall importance: 0.853

d_t:

Overall importance: 0.171

Cluster 2:

Documents: KsgGrWp1

Size: 1 documents

Characteristic features:

- i_y: 0.872 (diff from mean: +0.030)

- z_s: 0.086 (diff from mean: +0.073)

- ti_ci: 0.020 (diff from mean: -
0.073)

Cluster 3:

Documents: KsgPrzem2

Size: 1 documents


Characteristic features:

- i_y: 0.708 (diff from mean: -
0.135)


- d_t: 0.269 (diff from mean: +0.220)

- ti_ci: 0.019 (diff from mean: -
0.074)

Składnia. Korpus




Składnia. Piśmienność pragmatyczna




Zróżnicowanie. Formulaiczność

Najczęstsze wspólne frazy




Najczęstsze wspólne frazy. KsgławKraK




S

Najczęstsze wspólne frazy. *coram nobis*



Najczęstsze wspólne frazy. *nota quod*



Zmiana


Przyrost słownictwa

Vocabulary Growth by Text




Stabilność leksyki. *debeo*, *compareo*, *recipio*

Word Emergence Patterns




Zmiana leksykalna. Widok ogólny

Word Emergence Patterns




Zmiana leksykalna. *electio*

Word Emergence Patterns



Zmiana leksykalna. *epistola*

Word Emergence Patterns



Wnioski

- kwantytatywna analiza wieloczynnikowa
- obiektywizacja w oparciu o dane korpusowe
- zwiększenie interpretowalności analiz: *distant* + *close reading*
- szeroki materiał porównawczy
- współpraca między historykami i językoznawcami